

필수 데이터 확보 및 설계 권고

현재 보고서의 전략 우선순위와 공개 API 확보 가능성을 기준으로 정리한 연구·프로젝트 실행용 데이터 명세입니다.

필수 데이터 확보 및 설계 권고

현재 보고서의 상위 전략과 공개 API의 실제 확보 가능성을 기준으로, 연구·프로젝트 실행에 필요한 데이터를 우선순위별로 정리한 문서입니다.

1. 전략별 데이터 확보 우선순위

우선순위	전략	반드시 필요한 데이터	확보 난이도	권고
1	ETF 듀얼모멘텀+추세+vol target	ETF 일봉 OHLCV, 거래대금, 상장일, ETF 분류, 벤치마크·무위험수익률	낮음	첫 MVP
2	유동성 상위주 모멘텀+품질+저변동	주식 일봉, 종목 이력, 기업행사, DART 재무제표·공시시각, 업종	중간	데이터 계층 완성 후
3	글로벌/국내 ETF risk parity	ETF 일봉, 환율, 금리, 자산군 분류	낮음~중간	1순위와 동시 개발 가능
4	가치+품질 팩터	PIT 재무제표, 시가총액, 주식 수, 기업행사	중간~높음	공시 일정·시점 관리 필수
5	Breakout/Donchian	원시 일봉 OHLCV, 거래정지·가격제한 정보	낮음	단순 기준선
6	LightGBM 횡단면 랭커	위 데이터 전체+feature registry+실험 이력	높음	팩터 전략 challenger
7	DART 실적 이벤트	정확한 공시 접수시각, 정정공시, 재무 수치	중간	자체 surprise부터
8	단기 평균회귀	분봉, 스프레드, 실현 체결비용	높음	비용 데이터 확보 후
9	뉴스·LLM	뉴스 원문·게시시각·종목·라이선스	매우 높음	공시 RAG부터
10	호가·마켓메이킹	전체 호가장·큐·틱·취소·체결 데이터	매우 높음	현재 프로젝트 제외

핵심 원칙은 많이 수집하는 것이 아니라 시점 일관성이 있는 일봉·종목 이력·기업행사·공시 데이터부터 완전하게 확보하는 것입니다.

2. 반드시 확보해야 할 핵심 데이터셋

P0 - 모든 전략의 기반

데이터셋	주요 필드	형태·타입	권장 원천
security_master	내부 종목 ID, 종목코드, ISIN, 종목명, 시장, 자산유형, 보통주/우선주/ETF, 상장·상폐일, 업종, 거래정지·관리종목 여부	이력형 테이블	KIS 종목 마스터+KRX 대조
trading_calendar	거래일, 개장·종료시각, 휴장, 임시휴장, 시장	DATE, TIMESTAMPTZ	KIS 영업일+KRX
bars_daily_raw	종목 ID, 거래일, 시가·고가·저가·종가, 거래량, 거래대금, 전일종가	Parquet/정형	KIS 기간 별 시세

데이터셋	주요 필드	형태·타입	권장 원천
bars_daily_adjusted	수정 OHLC, 수정계수, 수정 사유, 계산 버전	파생 테이블	원시가격+기업행사 자체 계산
corporate_actions	배당, 분할·병합, 유무상증자, 합병, 권리락, 기준일·효력일·지급일, 비율·금액	이벤트 테이블	KIS 예약원 정보+DART+KRX
universe_history	날짜, 종목 ID, 편입 여부, 제외 사유, 유동성·상장기간 기준	일별/월별 snapshot	자체 계산
index_daily	KOSPI, KOSPI200, KOSDAQ, KOSDAQ150 OHLCV	일봉	KIS 업종·지수 시세
ingestion_runs	수집시각, 요청 파라미터, 응답 hash, 성공 여부, 오류, 행 수	감사 메타데이터	자체 생성

KIS 공식 예제에는 국내주식 기간별 일·주·월·년 시세, 원주가/수정주가 선택, 지수 일별 시세, 분봉, 투자자 동향, 재무비율, 배당·무상증자 일정 등의 호출 예제가 공개되어 있습니다. [KIS 국내주식 공식 예제](#)

P1 - ETF 전략용

데이터셋	필수 필드	비고
etf_master	ETF 코드, 운용사, 기초지수, 자산군, 국내/해외, 환헤지, 레버리지·인버스 여부, 상장일	최초 10~30개로 제한
etf_daily_metrics	거래대금, AUM, NAV·iNAV, 괴리율, 추적오차	긴 역사 확보는 권장사항
risk_free_rate	기준일, 금리 종류, 연율, 발표·수집시각	ECOS 금리
fx_daily	USD/KRW 등 환율, 적용일, 발표시각	해외자산 ETF
asset_class_map	주식·채권·금·원자재·현금성, 지역, 통화	버전형 metadata

첫 MVP에서는 AUM·추적오차보다 상장 후 1년 이상, 충분한 거래대금, 레버리지·인버스 제외, 동일 기초지수 중 유동성 우수 상품 선택이 중요합니다. ECOS는 금리·환율·통화·경기 통계를 Open API로 제공합니다. [한국은행 ECOS Open API](#)

P1 - 주식 팩터 전략용

데이터셋	주요 필드	주의점
dart_corp_map	corp_code, 종목코드, 회사명, 최근변경일	종목코드와 DART 코드 분리
filings	접수번호, 회사, 보고서명, 접수시각, 정정 여부, 원문 URL	known_at 핵심
financial_facts	연결/별도, 재무제표 구분, 표준계정 ID, 계정명, 기간, 금액, 통화·단위	long format 권장
shares_outstanding	발행·유통주식 수, 효력일, 공시시각	시가총액 계산
sector_history	업종 코드, 적용 시작·종료일	현재 업종 소급 금지
market_cap_daily	종가×당시 발행주식 수	현재 주식 수 사용 금지
listing_status_history	정상·정지·관리·상폐·정리매매 상태	생존편향 방지

Open DART는 회사 고유번호, 공시, 전체 재무제표 JSON/XML과 원본 XBRL을 제공합니다. 정정공시가 발생할 수 있으므로 이전 응답을 덮어쓰지 않습니다. [고유번호 API](#) · [전체 재무제표 API](#) · [원본 XBRL API](#)

권장 financial_facts 필드는 security_id, corp_code, rcept_no, report_code, fiscal_period_end, filed_at, known_at, statement_type, fs_scope, account_id, account_name, amount, currency, version입니다.

3. LightGBM 확장 데이터

Feature 군	원천 데이터	예시
가격 모멘텀	일봉	1/3/6/12개월 수익, 12-1 모멘텀
변동성	일봉	20/60/120일 실현변동성, downside vol
유동성	가격·거래량·거래대금	ADV20, turnover, Amihud
가격 위치	OHLC	52주 고점 거리, Donchian 위치
품질	DART	ROE, 영업이익률, 현금흐름, 발생액
가치	DART+시가총액	P/B, P/E, EV/EBITDA, FCF yield
안전성	DART	부채비율, 이자보상배율, 유동비율
성장성	DART	매출·영업이익 YoY
시장 노출	주식·지수 일봉	beta, residual volatility
업종 상대값	업종 이력	sector z-score-rank
거래주체	KIS 투자자 동향	외국인·기관 순매수 비율
거시	ECOS	금리·환율·term spread

각 feature에는 feature_name, formula_version, observation_date, known_at, lookback, lag_days, source_dataset, missing_policy, winsorization_version, computed_at을 저장합니다.

4. 연구용 저장 형태

Raw 계층

API 응답 JSON·XML·ZIP을 그대로 보존합니다.

```
data/raw/source=kis/dataset=bars_daily/ingest_date=2026-08-14/  
data/raw/source=dart/dataset=filings/ingest_date=2026-08-14/  
data/raw/source=ecos/dataset=macro/ingest_date=2026-08-14/
```

각 파일에 요청 URL·파라미터, 수집시각, HTTP/API 상태, 응답 SHA-256, API·파서 버전, 재시도 횟수, 이용조건을 기록합니다.

정제 계층

연구 데이터는 Parquet, 메타데이터·주문·감사로그는 PostgreSQL을 권장합니다.

```
data/curated/bars_daily/market=KOSPI/year=2026/  
data/curated/financial_facts/fiscal_year=2025/  
data/features/momentum/version=1/year=2026/
```

가격·금액은 NUMERIC, 거래량·주식 수는 BIGINT, 날짜는 DATE, 공시·체결·수집시각은 TIMESTAMPTZ, 종목코드는 STRING으로 저장합니다. CSV는 교환용으로만 사용하고 canonical 데이터로 사용하지 않습니다.

5. 절대 섞으면 안 되는 시간과 가격

모든 데이터는 effective_at(경제적 효력), known_at(알 수 있었던 시점), ingested_at(수집시점)을 가져야 합니다. 가격도 raw_close, adjusted_close, adjustment_factor, tradable_price를 분리합니다. 수정가격을 주문 체결가격으로 사용하면 안 됩니다.

6. API별 현실적인 평가

원천	확보가 쉬운 데이터	어려운 부분	평가
KIS Open API	현재·기간별 시세, 지수, 분봉, 투자자 동향, 주문·체결, 종목 마스터	호출 제한, 긴 역사 완전성, 제3자 이용범위	MVP 핵심
Open DART	회사 코드, 공시, 재무제표, XBRL	계정 표준화, 정정·연결/별도	팩터 핵심
ECOS	금리·환율·통화·거시	발표시각·개정치	ETF/risk parity 핵심
KRX 데이터포털	공식 시장·종목·지수 대조	안정적인 공개 REST 수집과 재배포 권리	검증 원천
KIS 종목 마스터	현재 종목·시장·업종·거래상태·상장일	과거 snapshot 복원 불가	매일 snapshot 필수
무료 비공식 래퍼	빠른 탐색	무보증·스키마·PIT·이용조건	탐색만

KIS 종목 마스터 정제 예제에는 종목코드·표준코드·종목명, 업종, 거래정지, 관리종목, 상장일, 상장주식 수 등의 필드가 포함됩니다. 현재 snapshot이므로 매일 보존해야 합니다. [KIS KOSDAQ 마스터 예제](#)

KRX/Koscom 정책은 실시간 데이터피드와 제3자 제공에 계약·승인 조건을 둡니다. 내부 연구 수집과 고객 대상 표시·API 제공을 분리해야 합니다. [KRX 시장정보 이용정책](#)

7. 초기에는 수집하지 않아도 되는 데이터

- 전체 호가장 Level 2, 틱 단위 주문·취소 흐름
- 초단위 뉴스, 소셜미디어 원문, 증권사 컨센서스
- 옵션 IV surface와 Greeks, 대차·공매도 상세 이력
- 위성·카드·앱 사용량 등 대체데이터
- LLM이 생성한 매수·매도 판단

분봉은 평균회귀보다 먼저 모의투자 체결비용 측정용으로 제한 수집하는 것이 좋습니다.

8. 권장 최소 구축 범위

첫 완료 기준은 security_master, security_master_snapshot, trading_calendar, bars_daily_raw, corporate_actions, bars_daily_adjusted, etf_master, index_daily, dart_filings, financial_facts, ingestion_runs, data_quality_results 12개 테이블입니다.

모의투자 단계에서 strategy_signals, target_positions, order_proposals, orders, fills, broker_positions, reconciliation_results를 추가합니다.

권장 수집 흐름은 다음과 같습니다.

KIS 종목 마스터 snapshot → ETF/주식 일봉 → 지수 일봉 → 기업행사 → DART 공시·재무 → ECOS 금리·환율 → 품질검사 → Parquet 확정

가장 큰 위험은 OHLCV 부족보다 과거 상폐종목과 당시 종목 상태를 복원하지 못하는 것입니다. 지금부터 매일 snapshot을 쌓고, 장기 백테스트 전에는 상폐·합병·코드변경 이력을 공식·상용 데이터로 보완해야 합니다.